

# MINERIA DE DATOS

- **Alumnas: Cordoba Maria de los Angeles**
- **Mansilla Fatima Ivanna**

## INTRODUCCION

El presente proyecto integrador se desarrolla en el marco de la asignatura **Minería de Datos 1**, con el propósito de aplicar de manera práctica las técnicas fundamentales de análisis de datos sobre un conjunto real denominado `streaming_users_dirty.json`. Este dataset contiene información sobre usuarios de plataformas de streaming, incluyendo variables numéricas (edad, horas de uso, tiempo de suscripción) y categóricas (plataforma, país, género).

La importancia de este trabajo radica en demostrar cómo, a partir de un dataset con problemas de calidad, es posible realizar un proceso completo de limpieza, exploración y reducción de dimensionalidad, obteniendo conclusiones útiles y comunicables. Además, se busca reforzar la trazabilidad del proceso y la claridad en la comunicación de resultados, tanto en un informe escrito como en una aplicación interactiva desarrollada en Streamlit.

## OBJETIVOS

1. **Inspeccionar el dataset inicial**, identificando su estructura, tipos de variables y problemas de calidad (valores faltantes, duplicados, inconsistencias).
2. **Preparar y limpiar los datos**, aplicando técnicas de imputación, normalización y eliminación de duplicados para garantizar confiabilidad.
3. **Realizar un análisis exploratorio (EDA)** que permita descubrir patrones, distribuciones y relaciones entre variables mediante visualizaciones y estadísticas descriptivas.
4. **Aplicar un análisis de componentes principales (PCA)** para reducir la dimensionalidad del dataset y sintetizar la información en componentes que expliquen la mayor parte de la variabilidad.
5. **Comunicar los hallazgos** en un informe final y en una aplicación interactiva, asegurando que los resultados sean claros, reproducibles y útiles para la interpretación de los hábitos de consumo de los usuarios.

## METODOLOGIA

El proyecto se desarrolló siguiendo un flujo ordenado de análisis de datos, dividido en cinco etapas principales:

### INSPECCIÓN INICIAL DEL DATASET

Se cargó el archivo `streaming_users_dirty.json` en Google Colab y se realizó una revisión de su estructura mediante funciones como `df.info()`, `df.head()` y `df.isnull().sum()`. Esto permitió identificar los tipos de variables (numéricas y

categorías), así como problemas de calidad como valores faltantes y registros duplicados.

## PREPARACIÓN Y LIMPIEZA DE DATOS

En esta etapa se aplicaron técnicas de calidad de datos:

- **Eliminación de duplicados** con `df.drop_duplicates()`.
- **Imputación de valores faltantes**: se utilizó la mediana para variables numéricas y el valor más frecuente para categóricas.
- **Normalización**: se aplicó `StandardScaler` para escalar las variables numéricas y garantizar comparabilidad.

El resultado fue un dataset limpio y confiable para los análisis posteriores.

## ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Se realizaron visualizaciones con **Seaborn** y **Matplotlib** para explorar patrones:

- Histogramas para observar la distribución de edad y horas de uso.
- Boxplots para comparar horas de uso entre plataformas y edades por género.
- Una matriz de correlación para identificar relaciones entre variables numéricas.

Este análisis permitió descubrir que los usuarios jóvenes consumen más horas de streaming y que existen diferencias significativas entre plataformas y países.

## ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)

Se aplicó PCA con dos componentes principales:

- Se calculó la **varianza explicada**, que mostró que los dos primeros componentes capturan gran parte de la información del dataset.
- Se analizaron las **cargas de las variables**, identificando que el PC1 está influido por edad y horas de uso, mientras que el PC2 refleja diferencias asociadas a plataforma y país.
- Se generó una visualización en el plano PC1–PC2 que permitió observar agrupamientos claros de usuarios.

## CONCLUSIONES Y COMUNICACIÓN DE RESULTADOS

Finalmente, se redactaron las conclusiones en un informe y se desarrolló una aplicación interactiva en **Streamlit** para facilitar la interpretación visual. El proyecto cumplió con los objetivos de trazabilidad, justificación y comunicación clara de resultados, integrando análisis estadístico y visualización interactiva.